



Chapitre XI - Échantillonnage et estimation

Bacomathiques — <https://bacomathiqu.es>

Table des matières

I - Définitions	1
II - Théorème de Moivre-Laplace	1
III - Intervalles de fluctuation	2
IV - Intervalles de confiance	3

I - Définitions

Lorsque l'on travaille sur une population de grande taille, il est rarement possible d'avoir accès à toutes les données de chacun des individus. C'est pourquoi on prélève **un échantillon** de cette population : c'est **l'échantillonnage**.

Un échantillon de taille n représente n individus choisis au hasard dans une population.

Il existe deux manières de réaliser un échantillonnage : sans remise (on prélève n individus différents) et avec remise (il est possible de prélever plusieurs fois le même individu).

II - Théorème de Moivre-Laplace

Soient $n \in \mathbb{N}$ et X_n une suite de variables aléatoires qui suivent la loi binomiale $B(n; p)$ (voir chapitre précédent). On définit alors la variable aléatoire Z_n :

$$Z_n = \frac{X_n - np}{\sqrt{np(1-p)}}$$

Soient a et $b \in \mathbb{R}$ tels que $a < b$, on a :

$$\lim_{n \rightarrow +\infty} p(a \leq Z_n \leq b) = \frac{1}{\sqrt{2\pi}} \times \int_a^b e^{-\frac{t^2}{2}} dx$$

Cela signifie que si on est dans les bonnes conditions d'approximation ($n \geq 30$, $np \geq 5$ et $n(1-p) \geq 5$), alors on peut avoir une bonne approximation de la variable aléatoire X_n (i.e. la loi binomiale de paramètre n et p) avec la loi normale de paramètres $(np; np(1-p))$.

III - Intervalles de fluctuation

Soient Z une variable aléatoire suivant la loi normale centrée réduite, α un réel et u_α un réel positif vérifiant $p(-u_\alpha \leq Z \leq u_\alpha) = 1 - \alpha$. On se donne également une variable aléatoire X_n suivant une loi binomiale $B(n; p)$ et on pose I_n l'intervalle de fluctuation asymptotique au seuil $1 - \alpha$:

$$I_n = \left[p - u_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}}; p + u_\alpha \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

On donne les conditions suivantes qui doivent être satisfaites :

- $n \geq 30$
- $np \geq 5$
- $n(1 - p) \geq 5$

En particulier, pour $\alpha = 0,05$, un intervalle de fluctuation au seuil de 95% de la fréquence d'apparition d'un caractère dans un échantillon aléatoire de taille n est :

$$J_n = \left[p - 1,96 \frac{\sqrt{p(1-p)}}{\sqrt{n}}; p + 1,96 \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

Cet intervalle J_n sera celui qui sera privilégié en classe de Terminale.

Exemple : Dans un lac dans lequel ne sont présents que deux types de poisson (truite et saumon), un groupe de pêcheurs réussit à attraper 50 poissons dans une journée. On estime qu'il y a environ 40 truites et 10 saumons.

Ils prélèvent au hasard 30 poissons de leur prise totale. Quel est l'intervalle de fluctuation asymptotique au seuil de 95% de la fréquence de saumon ?

Résolution : On a 50 poissons, la proportion de saumons est $p = \frac{10}{50} = 0,2$. La taille de l'échantillon est $n = 30$.

On a bien $n = 30 \geq 30$, $n \times p = 30 \times 0,2 = 6 \geq 5$ et $n \times (1 - p) = 30 \times (1 - 0,2) = 24 \geq 5$.

Voici donc l'intervalle de fluctuation asymptotique au seuil de 95% :

$$I = \left[0,2 - 1,96 \frac{\sqrt{0,2 \times 0,8}}{\sqrt{30}}; 0,2 + 1,96 \frac{\sqrt{0,2 \times 0,8}}{\sqrt{30}} \right] \approx [0,057; 0,343]$$

Ainsi, cela signifie que la fréquence f a 95% de chances de se situer dans l'intervalle I .

Ce type d'intervalle peut servir à prendre des décisions. En effet, soit I un intervalle de fluctuation asymptotique au seuil de 95%. On souhaite avoir une certaine fréquence f d'un

certain caractère. On peut dire qu'il est impossible d'avoir ce caractère si $f \notin I$ et qu'il possible d'avoir ce caractère si $f \in I$ avec toujours 5% de chances de se tromper.

IV - Intervalles de confiance

Soient une expérience de Bernoulli dont on veut estimer la probabilité de succès p et f_n la fréquence de succès après n répétitions indépendantes de l'épreuve. Alors p a 95% de chances d'appartenir à l'intervalle I_C suivant :

$$I_C = \left[f_n - \frac{1}{\sqrt{n}}; f_n + \frac{1}{\sqrt{n}} \right]$$

On donne les conditions suivantes qui doivent être satisfaites :

- $n \geq 30$
- $nf_n \geq 5$
- $n(1 - f_n) \geq 5$

Exemple : On dispose d'un paquet de 52 cartes. On les prend une par une et on les retourne jusqu'à ce qu'il ne reste plus que 22 cartes dans le paquet (on a donc tiré 30 cartes en tout).

On obtient 18 cartes rouges et 12 cartes noires. Dans quel intervalle de confiance au seuil de 95% se situe la probabilité p de tirer une carte rouge ?

Résolution : La taille de l'échantillon est $n = 30$. On a 18 cartes rouges, la fréquence observée de cartes rouges est donc $f_n = \frac{18}{30} = 0,6$.

On a bien $n = 30 \geq 30$, $n \times f_n = 30 \times 0,6 = 18 \geq 5$ et $n \times (1 - f_n) = 30 \times (1 - 0,6) = 12 \geq 5$.

La probabilité p de tirer une carte rouge se situe donc dans l'intervalle I_C avec une marge d'erreur de 5

$$I_C = \left[0,6 - \frac{1}{\sqrt{30}}; 0,6 + \frac{1}{\sqrt{30}} \right] \approx [0,417; 0,783]$$

Remarque : Dans un jeu de cartes classique, on a autant de chances de tirer une carte rouge que de tirer une carte noire. La "vraie" probabilité est donc de 0,5. Notre estimation est donc bonne car $0,5 \in I_C$.